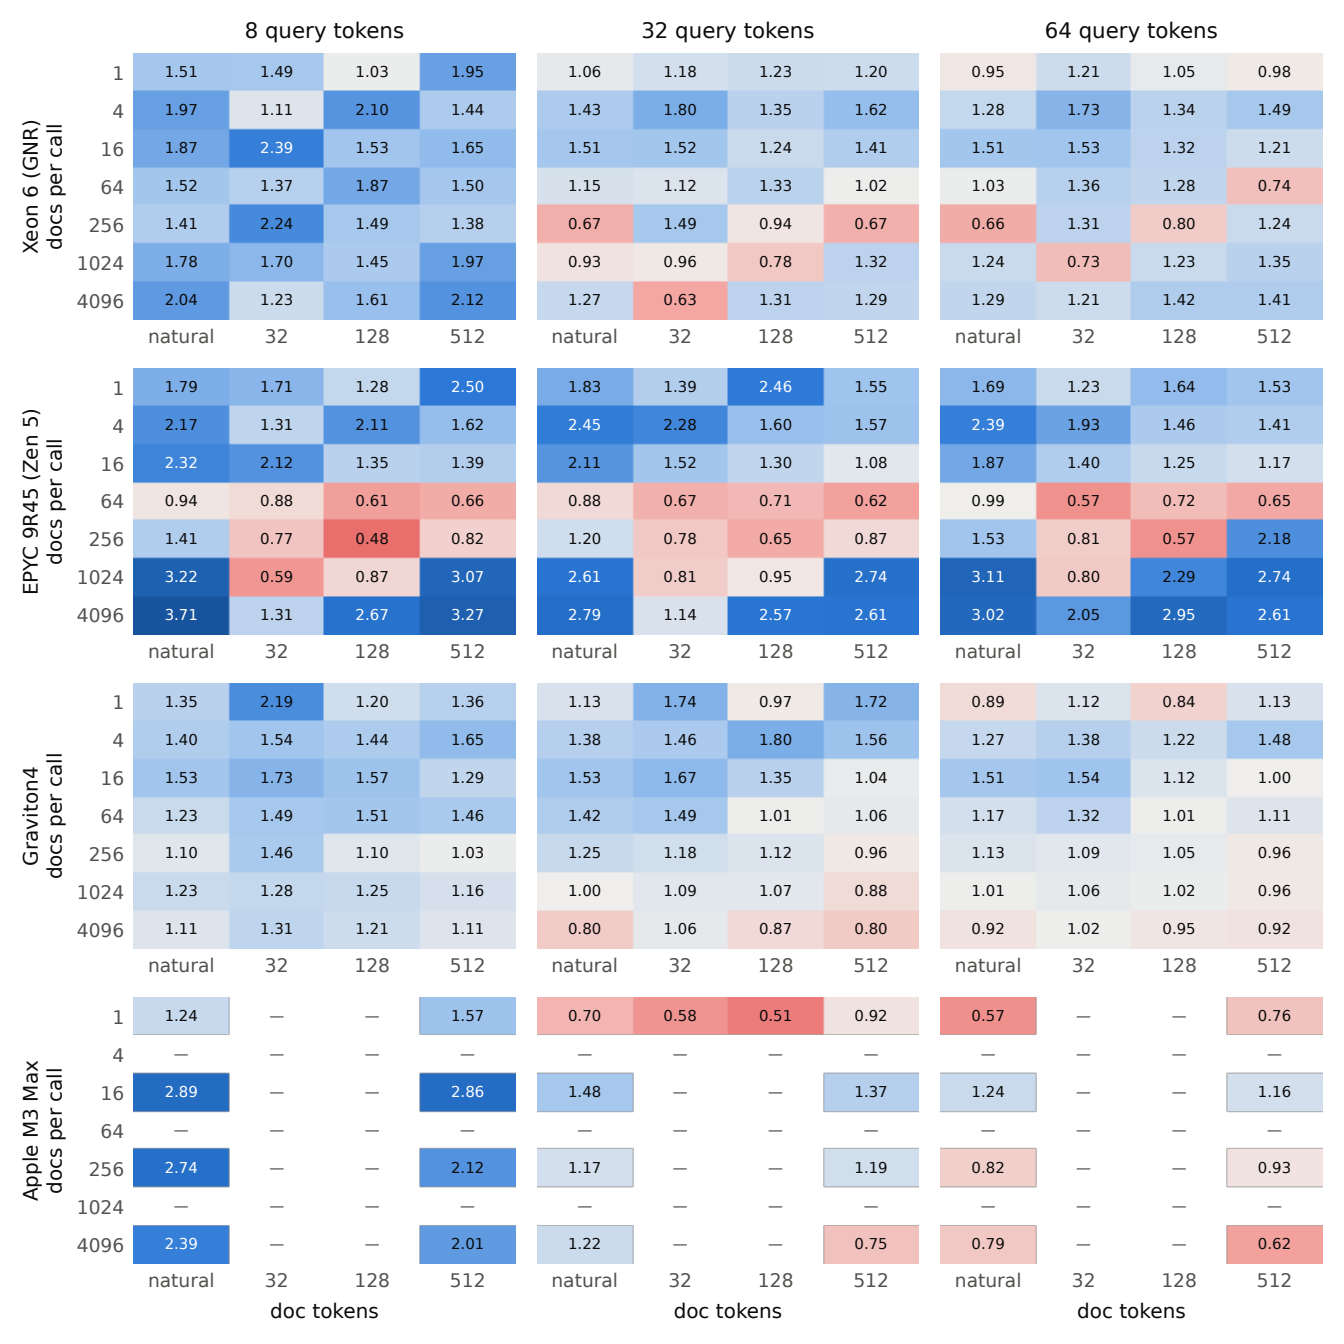
8 query tokens
32 query tokens
64 query tokens
Xeon 6 (GNR)
docs per call
1 1.51 1.49 1.03 1.95 1.06 1.18 1.23 1.20 0.95 1.21 1.05 0.98
4 1.97 1.11 2.10 1.44 1.43 1.80 1.35 1.62 1.28 1.73 1.34 1.49
16 1.87 2.39 1.53 1.65 1.51 1.52 1.24 1.41 1.51 1.53 1.32 1.21
64 1.52 1.37 1.87 1.50 1.15 1.12 1.33 1.02 1.03 1.36 1.28 0.74
256 1.41 2.24 1.49 1.38 0.67 1.49 0.94 0.67 0.66 1.31 0.80 1.24
1024 1.78 1.70 1.45 1.97 0.93 0.96 0.78 1.32 1.24 0.73 1.23 1.35
4096 2.04 1.23 1.61 2.12 1.27 0.63 1.31 1.29 1.29 1.21 1.42 1.41
natural 32 128 512 natural 32 128 512 natural 32 128 512
EPYC 9R45 (Zen 5)
docs per call
1 1.79 1.71 1.28 2.50 1.83 1.39 2.46 1.55 1.69 1.23 1.64 1.53
4 2.17 1.31 2.11 1.62 2.45 2.28 1.60 1.57 2.39 1.93 1.46 1.41
16 2.32 2.12 1.35 1.39 2.11 1.52 1.30 1.08 1.87 1.40 1.25 1.17
64 0.94 0.88 0.61 0.66 0.88 0.67 0.71 0.62 0.99 0.57 0.72 0.65
256 1.41 0.77 0.48 0.82 1.20 0.78 0.65 0.87 1.53 0.81 0.57 2.18
1024 3.22 0.59 0.87 3.07 2.61 0.81 0.95 2.74 3.11 0.80 2.29 2.74
4096 3.71 1.31 2.67 3.27 2.79 1.14 2.57 2.61 3.02 2.05 2.95 2.61
natural 32 128 512 natural 32 128 512 natural 32 128 512
Graviton4
docs per call
1 1.35 2.19 1.20 1.36 1.13 1.74 0.97 1.72 0.89 1.12 0.84 1.13
4 1.40 1.54 1.44 1.65 1.38 1.46 1.80 1.56 1.27 1.38 1.22 1.48
16 1.53 1.73 1.57 1.29 1.53 1.67 1.35 1.04 1.51 1.54 1.12 1.00
64 1.23 1.49 1.51 1.46 1.42 1.49 1.01 1.06 1.17 1.32 1.01 1.11
256 1.10 1.46 1.10 1.03 1.25 1.18 1.12 0.96 1.13 1.09 1.05 0.96
1024 1.23 1.28 1.25 1.16 1.00 1.09 1.07 0.88 1.01 1.06 1.02 0.96
4096 1.11 1.31 1.21 1.11 0.80 1.06 0.87 0.80 0.92 1.02 0.95 0.92
natural 32 128 512 natural 32 128 512 natural 32 128 512
Apple M3 Max
docs per call
1 1.24 — — 1.57 0.70 0.58 0.51 0.92 0.57 — — 0.76
4 — — — — — — — — — — — —
16 2.89 — — 2.86 1.48 — — 1.37 1.24 — — 1.16
64 — — — — — — — — — — — —
256 2.74 — — 2.12 1.17 — — 1.19 0.82 — — 0.93
1024 — — — — — — — — — — — —
4096 2.39 — — 2.01 1.22 — — 0.75 0.79 — — 0.62
natural 32 128 512 natural 32 128 512 natural 32 128 512
doc tokens
doc tokens
doc tokens